

# Selección de Instancias basada en Metaheurísticas para el Entrenamiento Compacto de Redes Neuronales Profundas

Trabajo de Fin de Máster  
Máster Universitario en Investigación en Inteligencia Artificial  
Universidad Internacional Menéndez Pelayo

**Autor:** Juan Manuel Rodríguez Gómez

**Tutores:** Óscar Cordon García y Pablo Mesejo Santiago

24 de septiembre de 2026



# Contenido

- 1 Introducción
- 2 Fundamentos y Estado del Arte
- 3 Metodología
- 4 Experimentación y Resultados
- 5 Conclusiones

## Motivación: ¿necesitamos todos los datos?

- Entrenar con grandes conjuntos de imágenes implica un **coste computacional elevado**.

## Motivación: ¿necesitamos todos los datos?

- Entrenar con grandes conjuntos de imágenes implica un **coste computacional elevado**.
- No todos los ejemplos aportan lo mismo: puede existir **información redundante**.

# Motivación: ¿necesitamos todos los datos?

- Entrenar con grandes conjuntos de imágenes implica un **coste computacional elevado**.
- No todos los ejemplos aportan lo mismo: puede existir **información redundante**.



## Motivación: ¿necesitamos todos los datos?

- Entrenar con grandes conjuntos de imágenes implica un **coste computacional elevado**.
- No todos los ejemplos aportan lo mismo: puede existir **información redundante**.



¿Podemos utilizar **menos datos**  
y mantener un **rendimiento similar**?

# Objetivos y preguntas de investigación

## Objetivo general

Evaluar la selección de instancias mediante **metaheurísticas** para obtener subconjuntos de entrenamiento compactos para **clasificadores profundos de imágenes**.

# Objetivos y preguntas de investigación

## Objetivo general

Evaluar la selección de instancias mediante **metaheurísticas** para obtener subconjuntos de entrenamiento compactos para **clasificadores profundos de imágenes**.

- 1 **Configuración inicial:** ¿qué combinación de representación y algoritmo seleccionar en la fase preliminar?

# Objetivos y preguntas de investigación

## Objetivo general

Evaluar la selección de instancias mediante **metaheurísticas** para obtener subconjuntos de entrenamiento compactos para **clasificadores profundos de imágenes**.

- 1 **Configuración inicial:** ¿qué combinación de representación y algoritmo seleccionar en la fase preliminar?
- 2 **Reducción de datos:** ¿cómo afecta al rendimiento predictivo y al tiempo de entrenamiento?

# Objetivos y preguntas de investigación

## Objetivo general

Evaluar la selección de instancias mediante **metaheurísticas** para obtener subconjuntos de entrenamiento compactos para **clasificadores profundos de imágenes**.

- 1 **Configuración inicial:** ¿qué combinación de representación y algoritmo seleccionar en la fase preliminar?
- 2 **Reducción de datos:** ¿cómo afecta al rendimiento predictivo y al tiempo de entrenamiento?
- 3 **Comparación de métodos:** ¿la configuración seleccionada ofrece ventajas frente a alternativas más simples?

# Objetivos y preguntas de investigación

## Objetivo general

Evaluar la selección de instancias mediante **metaheurísticas** para obtener subconjuntos de entrenamiento compactos para **clasificadores profundos de imágenes**.

- 1 **Configuración inicial:** ¿qué combinación de representación y algoritmo seleccionar en la fase preliminar?
- 2 **Reducción de datos:** ¿cómo afecta al rendimiento predictivo y al tiempo de entrenamiento?
- 3 **Comparación de métodos:** ¿la configuración seleccionada ofrece ventajas frente a alternativas más simples?
- 4 **Balance global:** ¿compensa el ahorro en entrenamiento el coste de seleccionar los datos?

## Selección de instancias: antecedentes

- **Selección de instancias:** conservar ejemplos originales, manteniendo sus imágenes y etiquetas.

---

[1] Olvera-López et al., "A review of instance selection methods," *Artif. Intell. Rev.*, 2010.

[2] García et al., "A memetic algorithm for evolutionary prototype selection: A scaling up approach," *Pattern Recognit.*, 2008.

[3] Sener y Savarese, "Active learning for convolutional neural networks: A core-set approach," *ICLR*, 2018.

## Selección de instancias: antecedentes

- **Selección de instancias:** conservar ejemplos originales, manteniendo sus imágenes y etiquetas.
- **Métodos clásicos [1]:** utilizan relaciones de vecindad para reducir redundancia o eliminar ruido.

---

[1] Olvera-López et al., "A review of instance selection methods," *Artif. Intell. Rev.*, 2010.

[2] García et al., "A memetic algorithm for evolutionary prototype selection: A scaling up approach," *Pattern Recognit.*, 2008.

[3] Sener y Savarese, "Active learning for convolutional neural networks: A core-set approach," *ICLR*, 2018.

## Selección de instancias: antecedentes

- **Selección de instancias:** conservar ejemplos originales, manteniendo sus imágenes y etiquetas.
- **Métodos clásicos [1]:** utilizan relaciones de vecindad para reducir redundancia o eliminar ruido.
- **Métodos evolutivos [2]:** exploran combinaciones de ejemplos mediante una población de subconjuntos.

---

[1] Olvera-López et al., "A review of instance selection methods," *Artif. Intell. Rev.*, 2010.

[2] García et al., "A memetic algorithm for evolutionary prototype selection: A scaling up approach," *Pattern Recognit.*, 2008.

[3] Sener y Savarese, "Active learning for convolutional neural networks: A core-set approach," *ICLR*, 2018.

## Selección de instancias: antecedentes

- **Selección de instancias:** conservar ejemplos originales, manteniendo sus imágenes y etiquetas.
- **Métodos clásicos [1]:** utilizan relaciones de vecindad para reducir redundancia o eliminar ruido.
- **Métodos evolutivos [2]:** exploran combinaciones de ejemplos mediante una población de subconjuntos.
- **Métodos geométricos [3]:** buscan cubrir el espacio de representaciones de los datos.

---

[1] Olvera-López et al., "A review of instance selection methods," *Artif. Intell. Rev.*, 2010.

[2] García et al., "A memetic algorithm for evolutionary prototype selection: A scaling up approach," *Pattern Recognit.*, 2008.

[3] Sener y Savarese, "Active learning for convolutional neural networks: A core-set approach," *ICLR*, 2018.

# ¿Por qué utilizar metaheurísticas?

- Elegir  $k$  ejemplos entre  $N$  genera **un problema combinatorio**:

$$\binom{N}{k} \text{ subconjuntos posibles.}$$

---

[4] Glover y Kochenberger, eds., *Handbook of Metaheuristics*, Springer, 2003.

# ¿Por qué utilizar metaheurísticas?

- Elegir  $k$  ejemplos entre  $N$  genera **un problema combinatorio**:

$$\binom{N}{k} \text{ subconjuntos posibles.}$$

- Evaluarlos todos es inviable: cada candidato requiere **entrenar un clasificador**.

---

[4] Glover y Kochenberger, eds., *Handbook of Metaheuristics*, Springer, 2003.

# ¿Por qué utilizar metaheurísticas?

- Elegir  $k$  ejemplos entre  $N$  genera **un problema combinatorio**:

$$\binom{N}{k} \text{ subconjuntos posibles.}$$

- Evaluarlos todos es inviable: cada candidato requiere **entrenar un clasificador**.
- Las metaheurísticas permiten una **búsqueda aproximada con un presupuesto limitado**, sin explorar todo el espacio ni garantizar el óptimo [4].

---

[4] Glover y Kochenberger, eds., *Handbook of Metaheuristics*, Springer, 2003.

# ¿Por qué utilizar metaheurísticas?

- Elegir  $k$  ejemplos entre  $N$  genera **un problema combinatorio**:

$$\binom{N}{k} \text{ subconjuntos posibles.}$$

- Evaluarlos todos es inviable: cada candidato requiere **entrenar un clasificador**.
- Las metaheurísticas permiten una **búsqueda aproximada con un presupuesto limitado**, sin explorar todo el espacio ni garantizar el óptimo [4].
- **Equilibrio entre exploración y explotación.**

---

[4] Glover y Kochenberger, eds., *Handbook of Metaheuristics*, Springer, 2003.

# Aprendizaje por transferencia

- Reutilizamos una red **preentrenada en ImageNet** como extractor de características [5].


---

[5] Pan y Yang, "A survey on transfer learning," *IEEE TKDE*, 2010.

[6] Kornblith et al., "Do better ImageNet models transfer better?" *CVPR*, 2019.

# Aprendizaje por transferencia

- Reutilizamos una red **preentrenada** en ImageNet como extractor de características [5].




---

[5] Pan y Yang, "A survey on transfer learning," *IEEE TKDE*, 2010.

[6] Kornblith et al., "Do better ImageNet models transfer better?" *CVPR*, 2019.

# Aprendizaje por transferencia

- Reutilizamos una red **preentrenada** en ImageNet como extractor de características [5].



- **Una sola extracción:** pesos fijos y características calculadas una única vez.


---

[5] Pan y Yang, "A survey on transfer learning," *IEEE TKDE*, 2010.

[6] Kornblith et al., "Do better ImageNet models transfer better?" *CVPR*, 2019.

# Aprendizaje por transferencia

- Reutilizamos una red **preentrenada** en ImageNet como extractor de características [5].




- **Una sola extracción:** pesos fijos y características calculadas una única vez.
- **Para cada subconjunto candidato:** nuevo **clasificador lineal** sobre las características seleccionadas [6].

---


[5] Pan y Yang, "A survey on transfer learning," *IEEE TKDE*, 2010.

[6] Kornblith et al., "Do better ImageNet models transfer better?" *CVPR*, 2019.

# Formulación: ¿qué subconjunto buscamos?




# Formulación: ¿qué subconjunto buscamos?



$$\sum_{i=1}^N z_i = k, \quad k \approx \rho N$$


# Formulación: ¿qué subconjunto buscamos?



$$\sum_{i=1}^N z_i = k, \quad k \approx \rho N$$

$$\rho \in \{10\%, 25\%, 50\%, 75\%, 90\%\}$$

# Formulación: ¿qué subconjunto buscamos?




$$\sum_{i=1}^N z_i = k, \quad k \approx \rho N$$

$$\rho \in \{10\%, 25\%, 50\%, 75\%, 90\%\}$$

Mismo tamaño de subconjunto: solo cambia qué ejemplos se seleccionan.

# ¿Cómo evaluamos un subconjunto?


## Durante la búsqueda




Repetir hasta  $B$  evaluaciones

# ¿Cómo evaluamos un subconjunto?

## Durante la búsqueda



## Después de la búsqueda



**El test no guía la selección**

**Repetir hasta  $B$  evaluaciones**

# Estrategias de búsqueda comparadas

## RS – Random Search

**Subconjuntos aleatorios  
independientes**

$z_1$        $z_2$        $z_3$       ...

**Misma cardinalidad · Mismo fitness · Mismo presupuesto  $B$**

# Estrategias de búsqueda comparadas

## RS – Random Search

Subconjuntos aleatorios  
independientes

$z_1$        $z_2$        $z_3$        $\dots$

## LNS – Large Neighborhood Search

Intercambios múltiples

$q$  salen  $\leftrightarrow$   $q$  entran

Misma cardinalidad · Mismo fitness · Mismo presupuesto  $B$

# Estrategias de búsqueda comparadas

## RS – Random Search

Subconjuntos aleatorios  
independientes

$z_1$        $z_2$        $z_3$       ...

## GA – Genetic Algorithm

Población de subconjuntos

Selección → Cruce → Mutación

## LNS – Large Neighborhood Search

Intercambios múltiples

$q$  salen ↔  $q$  entran

Misma cardinalidad · Mismo fitness · Mismo presupuesto  $B$

# Estrategias de búsqueda comparadas

## RS – Random Search

Subconjuntos aleatorios  
independientes

$z_1$        $z_2$        $z_3$       ...

## GA – Genetic Algorithm

Población de subconjuntos

Selección → Cruce → Mutación

## LNS – Large Neighborhood Search

Intercambios múltiples

$q$  salen  $\leftrightarrow$   $q$  entran

## MA – Memetic Algorithm

GA + refinamiento local

Sobre algunos descendientes

Misma cardinalidad · Mismo fitness · Mismo presupuesto  $B$

# Métodos de referencia de la fase principal

SSRS y KCG no entrenan clasificadores para seleccionar; el **100 %** sirve de referencia sin reducción.

## SSRS

### Single Stratified Random Sample

Un único subconjunto  
aleatorio y estratificado  
por clase.

0 evals.

# Métodos de referencia de la fase principal

SSRS y KCG no entrenan clasificadores para seleccionar; el **100 %** sirve de referencia sin reducción.

## SSRS

**Single Stratified  
Random Sample**

Un único subconjunto  
**aleatorio y estratificado**  
por clase.

**0 evals.**

## KCG

**Global  $k$ -Center  
Greedy**

Selección **geométrica**  
para cubrir el espacio  
de características.

**0 evals.**

# Métodos de referencia de la fase principal

SSRS y KCG no entrenan clasificadores para seleccionar; el **100 %** sirve de referencia sin reducción.

## SSRS

### Single Stratified Random Sample

Un único subconjunto  
**aleatorio y estratificado**  
por clase.

**0 evals.**

## KCG

### Global $k$ -Center Greedy

Selección **geométrica**  
para cubrir el espacio  
de características.

**0 evals.**

## 100 %

### Conjunto de entrenamiento completo

Entrenamiento con  
**todos los ejemplos**  
del conjunto base.

# Diseño experimental en dos etapas

## Etapa 1 – Screening

### MNIST

#### 4 arquitecturas de red

AlexNet · ResNeXt-50  
EfficientNetV2-S · Swin-T

#### 4 estrategias

RS · LNS · GA · MA

#### 400 búsquedas

$B = 100$  evals.

# Diseño experimental en dos etapas

## Etapa 1 – Screening

### MNIST

#### 4 arquitecturas de red

AlexNet · ResNeXt-50  
EfficientNetV2-S · Swin-T

#### 4 estrategias

RS · LNS · GA · MA

#### 400 búsquedas

$B = 100$  evals.



## Etapa 2 – Estudio principal

### CIFAR-10 Tiny ImageNet

Configuración seleccionada  
+ RS

#### Referencias

SSRS · KCG · 100 %

#### 100 búsquedas

$B = 1000$  evals.

# Diseño experimental en dos etapas

## Etapa 1 – Screening

### MNIST

#### 4 arquitecturas de red

AlexNet · ResNeXt-50  
EfficientNetV2-S · Swin-T

#### 4 estrategias

RS · LNS · GA · MA

#### 400 búsquedas

$B = 100$  evals.



## Etapa 2 – Estudio principal

### CIFAR-10 Tiny ImageNet

Configuración seleccionada  
+ RS

#### Referencias

SSRS · KCG · 100 %

#### 100 búsquedas

$B = 1000$  evals.

**Común a ambas etapas:**  $\rho = \{10, 25, 50, 75, 90\} \%$  · 5 semillas

# Diseño experimental en dos etapas

## Etapa 1 – Screening

### MNIST

#### 4 arquitecturas de red

AlexNet · ResNeXt-50  
EfficientNetV2-S · Swin-T

#### 4 estrategias

RS · LNS · GA · MA

#### 400 búsquedas

$B = 100$  evals.



## Etapa 2 – Estudio principal

### CIFAR-10 Tiny ImageNet

Configuración seleccionada  
+ RS

#### Referencias

SSRS · KCG · 100 %

#### 100 búsquedas

$B = 1000$  evals.

**Común a ambas etapas:**  $\rho = \{10, 25, 50, 75, 90\} \%$  · 5 semillas

**500 búsquedas · 140 000 evaluaciones**

Cientos de horas de cómputo.

# Datasets y particiones

Tres datasets con **complejidad visual creciente**.

| Dataset       | Clases | Base train | Validación | Test   |
|---------------|--------|------------|------------|--------|
| MNIST         | 10     | 48 000     | 12 000     | 10 000 |
| CIFAR-10      | 10     | 40 000     | 10 000     | 10 000 |
| Tiny ImageNet | 200    | 80 000     | 20 000     | 10 000 |

# Datasets y particiones

Tres datasets con **complejidad visual creciente**.

| Dataset       | Clases | Base train | Validación | Test   |
|---------------|--------|------------|------------|--------|
| MNIST         | 10     | 48 000     | 12 000     | 10 000 |
| CIFAR-10      | 10     | 40 000     | 10 000     | 10 000 |
| Tiny ImageNet | 200    | 80 000     | 20 000     | 10 000 |

## Base train

Espacio sobre el que se seleccionan las instancias.

## Validación

Evalúa los candidatos durante la búsqueda.

## Test

Reservado para la evaluación final.

# Datasets y particiones

Tres datasets con **complejidad visual creciente**.

| Dataset       | Clases | Base train | Validación | Test   |
|---------------|--------|------------|------------|--------|
| MNIST         | 10     | 48 000     | 12 000     | 10 000 |
| CIFAR-10      | 10     | 40 000     | 10 000     | 10 000 |
| Tiny ImageNet | 200    | 80 000     | 20 000     | 10 000 |

## Base train

Espacio sobre el que se seleccionan las instancias.

## Validación

Evalúa los candidatos durante la búsqueda.

## Test

Reservado para la evaluación final.

Split train/validación: **80/20 estratificado y determinista** · seed = 42

# Configuración experimental común

Mismo protocolo de entrenamiento para garantizar una **comparación controlada**.

## Entrenamiento

### Clasificador lineal

|               |             |
|---------------|-------------|
| Épocas        | 10          |
| Batch size    | 32          |
| Optimizador   | <b>Adam</b> |
| Learning rate | $10^{-3}$   |
| Weight decay  | 0           |

**Extractor profundo congelado**

# Configuración experimental común

Mismo protocolo de entrenamiento para garantizar una **comparación controlada**.

## Entrenamiento

### Clasificador lineal

|               |           |
|---------------|-----------|
| Épocas        | 10        |
| Batch size    | 32        |
| Optimizador   | Adam      |
| Learning rate | $10^{-3}$ |
| Weight decay  | 0         |

**Extractor profundo congelado**

## Evaluación

### Fitness de búsqueda

Accuracy sobre validación

### Evaluación final

Accuracy · Precision · Recall · F1  
métricas macro

**Checkpoint con menor validation  
loss**

# Configuración experimental común

Mismo protocolo de entrenamiento para garantizar una **comparación controlada**.

## Entrenamiento

### Clasificador lineal

|               |           |
|---------------|-----------|
| Épocas        | 10        |
| Batch size    | 32        |
| Optimizador   | Adam      |
| Learning rate | $10^{-3}$ |
| Weight decay  | 0         |

Extractor profundo congelado

## Evaluación

### Fitness de búsqueda

Accuracy sobre validación

### Evaluación final

Accuracy · Precision · Recall · F1  
métricas macro

Checkpoint con menor validation  
loss

Sin early stopping · Entrenamiento determinista  
Mismas condiciones entre métodos

## Fase preliminar: selección de la configuración

Resultados agregados sobre **5 retenciones**  $\times$  **5 semillas** con  $B = 100$ .

### Mejores configuraciones

| Extractor      | Alg.      | Acc.          | Rank        | Wins     |
|----------------|-----------|---------------|-------------|----------|
| <b>AlexNet</b> | <b>GA</b> | <b>96.976</b> | <b>1.60</b> | <b>3</b> |
| AlexNet        | RS        | 96.944        | 2.70        | 0        |
| AlexNet        | MA        | 96.944        | 3.10        | 0        |
| ResNeXt-50     | GA        | 96.918        | 3.40        | 2        |
| AlexNet        | LNS       | 96.891        | 4.80        | 0        |

Accuracy de validación media (%).  
Rank y wins calculados por semilla.

## Fase preliminar: selección de la configuración

Resultados agregados sobre **5 retenciones** × **5 semillas** con  $B = 100$ .

### Mejores configuraciones

| Extractor      | Alg.      | Acc.          | Rank        | Wins     |
|----------------|-----------|---------------|-------------|----------|
| <b>AlexNet</b> | <b>GA</b> | <b>96.976</b> | <b>1.60</b> | <b>3</b> |
| AlexNet        | RS        | 96.944        | 2.70        | 0        |
| AlexNet        | MA        | 96.944        | 3.10        | 0        |
| ResNeXt-50     | GA        | 96.918        | 3.40        | 2        |
| AlexNet        | LNS       | 96.891        | 4.80        | 0        |

Accuracy de validación media (%).  
Rank y wins calculados por semilla.

### Configuración seleccionada

**AlexNet + GA**

**Pasa a la Etapa 2**

## Fase preliminar: selección de la configuración

Resultados agregados sobre **5 retenciones**  $\times$  **5 semillas** con  $B = 100$ .

### Mejores configuraciones

| Extractor      | Alg.      | Acc.          | Rank        | Wins     |
|----------------|-----------|---------------|-------------|----------|
| <b>AlexNet</b> | <b>GA</b> | <b>96.976</b> | <b>1.60</b> | <b>3</b> |
| AlexNet        | RS        | 96.944        | 2.70        | 0        |
| AlexNet        | MA        | 96.944        | 3.10        | 0        |
| ResNeXt-50     | GA        | 96.918        | 3.40        | 2        |
| AlexNet        | LNS       | 96.891        | 4.80        | 0        |

Accuracy de validación media (%).  
Rank y wins calculados por semilla.

### Configuración seleccionada


**AlexNet + GA**

**Pasa a la Etapa 2**

**Ventaja frente a AlexNet + RS/MA: solo 0.032 pp**


# Fase principal: CIFAR-10

AlexNet congelado · 5 semillas · Accuracy sobre test independiente



# Fase principal: CIFAR-10


AlexNet congelado · 5 semillas · Accuracy sobre test independiente



**GA 90 %: 80.87 %    vs.    100 %: 80.95 %    (solo -0.08 pp)**


# Fase principal: Tiny ImageNet

AlexNet congelado · 5 semillas · Accuracy sobre test independiente



# Fase principal: Tiny ImageNet

AlexNet congelado · 5 semillas · Accuracy sobre test independiente



**KCG 25 %: 45.72 %    vs.    100 %: 45.95 %    (solo -0.23 pp)**

# Comparación global de los métodos

Ranking descriptivo sobre **25 bloques por dataset** (5 retenciones  $\times$  5 semillas).  
Menor rank = mejor.

## CIFAR-10

| Método    | Rank        | Wins      |
|-----------|-------------|-----------|
| <b>GA</b> | <b>1.80</b> | <b>11</b> |
| RS        | 2.52        | 8         |
| SSRS      | 2.84        | 2         |
| KCG       | 2.84        | 4         |

**GA: menor rank medio**

# Comparación global de los métodos

Ranking descriptivo sobre **25 bloques por dataset** (5 retenciones  $\times$  5 semillas).  
Menor rank = mejor.

## CIFAR-10

| Método    | Rank        | Wins      |
|-----------|-------------|-----------|
| <b>GA</b> | <b>1.80</b> | <b>11</b> |
| RS        | 2.52        | 8         |
| SSRS      | 2.84        | 2         |
| KCG       | 2.84        | 4         |

**GA: menor rank medio**

## Tiny ImageNet

| Método    | Rank        | Wins     |
|-----------|-------------|----------|
| <b>RS</b> | <b>2.40</b> | <b>7</b> |
| SSRS      | 2.44        | 6        |
| GA        | 2.52        | 4        |
| KCG       | 2.64        | <b>8</b> |

**Ranks muy próximos**

# Comparación global de los métodos

Ranking descriptivo sobre **25 bloques por dataset** (5 retenciones  $\times$  5 semillas).  
Menor rank = mejor.

## CIFAR-10

| Método | Rank | Wins |
|--------|------|------|
| GA     | 1.80 | 11   |
| RS     | 2.52 | 8    |
| SSRS   | 2.84 | 2    |
| KCG    | 2.84 | 4    |

**GA: menor rank medio**

## Tiny ImageNet

| Método | Rank | Wins |
|--------|------|------|
| RS     | 2.40 | 7    |
| SSRS   | 2.44 | 6    |
| GA     | 2.52 | 4    |
| KCG    | 2.64 | 8    |

**Ranks muy próximos**

**Diagnóstico estadístico:** Friedman global sobre 5 agregados por semilla.

**Con solo 5 semillas, no podemos establecer diferencias significativas entre pares de métodos mediante Wilcoxon exacto bilateral ( $\alpha = 0.05$ ).**

# Reducción de datos y tiempo de entrenamiento

Pérdida de accuracy frente al **ahorro en entrenamiento final**.

**CIFAR-10**

| Config.   | $\Delta$ acc. (pp) | Ahorro        |
|-----------|--------------------|---------------|
| 100 %     | —                  | —             |
| GA 90 %   | <b>-0.08</b>       | 8.0 %         |
| SSRS 75 % | -0.53              | 18.6 %        |
| RS 50 %   | -0.74              | <b>43.5 %</b> |

# Reducción de datos y tiempo de entrenamiento

Pérdida de accuracy frente al **ahorro en entrenamiento final**.

## CIFAR-10

| Config.   | $\Delta$ acc. (pp) | Ahorro        |
|-----------|--------------------|---------------|
| 100 %     | —                  | —             |
| GA 90 %   | <b>-0.08</b>       | 8.0 %         |
| SSRS 75 % | -0.53              | 18.6 %        |
| RS 50 %   | -0.74              | <b>43.5 %</b> |

## Tiny ImageNet

| Config.  | $\Delta$ acc. (pp) | Ahorro        |
|----------|--------------------|---------------|
| 100 %    | —                  | —             |
| KCG 25 % | <b>-0.23</b>       | <b>60.9 %</b> |
| RS 50 %  | -2.28              | 40.9 %        |

# Reducción de datos y tiempo de entrenamiento

Pérdida de accuracy frente al **ahorro en entrenamiento final**.

## CIFAR-10

| Config.   | $\Delta$ acc. (pp) | Ahorro        |
|-----------|--------------------|---------------|
| 100 %     | —                  | —             |
| GA 90 %   | <b>-0.08</b>       | 8.0 %         |
| SSRS 75 % | -0.53              | 18.6 %        |
| RS 50 %   | -0.74              | <b>43.5 %</b> |

## Tiny ImageNet

| Config.  | $\Delta$ acc. (pp) | Ahorro        |
|----------|--------------------|---------------|
| 100 %    | —                  | —             |
| KCG 25 % | <b>-0.23</b>       | <b>60.9 %</b> |
| RS 50 %  | -2.28              | 40.9 %        |

**¿Y cuánto cuesta encontrar estos subconjuntos?**

## Coste de selección: ¿compensa la búsqueda?

El ahorro del entrenamiento final debe compararse con el **coste de encontrar el subconjunto**.

### CIFAR-10

GA / RS  
99–448 min

KCG  
6.5 min

caché + primer recorrido

SSRS  
< 0.06 s

**Entrenamiento final: 6–28 s**

## Coste de selección: ¿compensa la búsqueda?

El ahorro del entrenamiento final debe compararse con el **coste de encontrar el subconjunto**.

### CIFAR-10

GA / RS  
99–448 min

KCG  
6.5 min

caché + primer recorrido

SSRS  
< 0.06 s

Entrenamiento final: 6–28 s

### Tiny ImageNet

GA / RS  
194–844 min

KCG  
24.9 min

caché + primer recorrido

SSRS  
< 0.06 s

Entrenamiento final: 11–54 s

## Coste de selección: ¿compensa la búsqueda?

El ahorro del entrenamiento final debe compararse con el **coste de encontrar el subconjunto**.

### CIFAR-10

GA / RS  
99–448 min

KCG  
6.5 min

caché + primer recorrido

SSRS  
< 0.06 s

Entrenamiento final: 6–28 s

### Tiny ImageNet

GA / RS  
194–844 min

KCG  
24.9 min

caché + primer recorrido

SSRS  
< 0.06 s

Entrenamiento final: 11–54 s

La búsqueda wrapper cuesta órdenes de magnitud más que un único entrenamiento final.

## Efecto del presupuesto de búsqueda

De las 100 búsquedas con  $B = 1000$ , ¿qué porcentaje había alcanzado ya su **mejor fitness final**?

Evaluación 100

10 %

## Efecto del presupuesto de búsqueda

De las 100 búsquedas con  $B = 1000$ , ¿qué porcentaje había alcanzado ya su mejor fitness final?

Evaluación 100

10 %

Evaluación 500

54 %

## Efecto del presupuesto de búsqueda

De las 100 búsquedas con  $B = 1000$ , ¿qué porcentaje había alcanzado ya su mejor fitness final?

Evaluación 100

10 %

Evaluación 500

54 %

Evaluación 750

90 %

## Efecto del presupuesto de búsqueda

De las 100 búsquedas con  $B = 1000$ , ¿qué porcentaje había alcanzado ya su mejor fitness final?

Evaluación 100

10 %

Evaluación 500

54 %

Evaluación 750

90 %

$B = 100$ : screening, no convergencia. Ni  $B = 1000$  la garantiza.

# Discusión: respuesta a las preguntas planteadas

Síntesis de los principales resultados obtenidos.

## Configuración inicial

**AlexNet + GA** obtuvo el mejor resultado agregado en MNIST.

Selección **descriptiva**:  
ventaja de solo **0.032 pp.**

# Discusión: respuesta a las preguntas planteadas

Síntesis de los principales resultados obtenidos.

## Configuración inicial

**AlexNet + GA** obtuvo el mejor resultado agregado en MNIST.

Selección **descriptiva**:  
ventaja de solo **0.032 pp.**

## Reducción de datos

Subconjuntos compactos pueden mantener un **rendimiento competitivo**.

Menos instancias reducen el **tiempo de entrenamiento final**.

# Discusión: respuesta a las preguntas planteadas

Síntesis de los principales resultados obtenidos.

## Configuración inicial

**AlexNet + GA** obtuvo el mejor resultado agregado en MNIST.

Selección **descriptiva**:  
ventaja de solo **0.032 pp.**

## Reducción de datos

Subconjuntos compactos pueden mantener un **rendimiento competitivo**.

Menos instancias reducen el **tiempo de entrenamiento final**.

## Comparación de métodos

**GA no mantiene una ventaja consistente** en todos los escenarios.

RS, SSRS y KCG también resultan **competitivos**.

# Discusión: respuesta a las preguntas planteadas

Síntesis de los principales resultados obtenidos.

## Configuración inicial

**AlexNet + GA** obtuvo el mejor resultado agregado en MNIST.

Selección **descriptiva**:  
ventaja de solo **0.032 pp.**

## Reducción de datos

Subconjuntos compactos pueden mantener un **rendimiento competitivo**.

Menos instancias reducen el **tiempo de entrenamiento final**.

## Comparación de métodos

GA **no mantiene una ventaja consistente** en todos los escenarios.

RS, SSRS y KCG también resultan **competitivos**.

## Balance global

El ahorro en entrenamiento puede ser importante.

Pero el **coste de selección** condiciona el beneficio total.

# Discusión: respuesta a las preguntas planteadas

Síntesis de los principales resultados obtenidos.

## Configuración inicial

**AlexNet + GA** obtuvo el mejor resultado agregado en MNIST.

Selección **descriptiva**:  
ventaja de solo **0.032 pp.**

## Reducción de datos

Subconjuntos compactos pueden mantener un **rendimiento competitivo**.

Menos instancias reducen el **tiempo de entrenamiento final**.

## Comparación de métodos

GA **no mantiene una ventaja consistente** en todos los escenarios.

RS, SSRS y KCG también resultan **competitivos**.

## Balance global

El ahorro en entrenamiento puede ser importante.

Pero el **coste de selección** condiciona el beneficio total.

**El valor práctico depende del rendimiento, el coste y la reutilización del subconjunto.**

# Conclusiones principales

## Datos compactos

Es posible utilizar  
**menos instancias**

manteniendo un  
**rendimiento  
competitivo**

y reduciendo el coste  
del **entrenamiento  
final**.

# Conclusiones principales

## Datos compactos

Es posible utilizar  
**menos instancias**

manteniendo un  
**rendimiento  
competitivo**

y reduciendo el coste  
del **entrenamiento  
final**.

## Métodos

Ningún método **domina  
sistemáticamente**.

GA es competitivo,  
pero **RS, SSRS y KCG**  
también ofrecen  
resultados sólidos.

# Conclusiones principales

## Datos compactos

Es posible utilizar **menos instancias**

manteniendo un **rendimiento competitivo**

y reduciendo el coste del **entrenamiento final**.

## Métodos

Ningún método **domina sistemáticamente**.

GA es competitivo, pero **RS, SSRS y KCG** también ofrecen resultados sólidos.

## Coste práctico

La búsqueda wrapper puede ser **muy costosa**.

Sus mejoras frente a referencias simples son **pequeñas e inconsistentes**.

La reutilización del subconjunto es clave para amortizarla.

# Conclusiones principales

## Datos compactos

Es posible utilizar **menos instancias**

manteniendo un **rendimiento competitivo**

y reduciendo el coste del **entrenamiento final**.

## Métodos

Ningún método **domina sistemáticamente**.

GA es competitivo, pero **RS, SSRS y KCG** también ofrecen resultados sólidos.

## Coste práctico

La búsqueda wrapper puede ser **muy costosa**.

Sus mejoras frente a referencias simples son **pequeñas e inconsistentes**.

La reutilización del subconjunto es clave para amortizarla.

**Reducir datos puede ser útil; una búsqueda costosa para seleccionarlos no siempre compensa.**

# Limitaciones y trabajo futuro

Principales límites del estudio y posibles extensiones.

## Limitaciones

- Evaluación lineal sobre **representaciones congeladas**; sin fine-tuning end-to-end.
- Incluso  $B = 1000$  explora una **fracción mínima** del espacio de subconjuntos.
- Solo **5 semillas** y una partición de validación; posible **sobreajuste**.

# Limitaciones y trabajo futuro

Principales límites del estudio y posibles extensiones.

## Limitaciones

- Evaluación lineal sobre **representaciones congeladas**; sin fine-tuning end-to-end.
- Incluso  $B = 1000$  explora una **fracción mínima** del espacio de subconjuntos.
- Solo **5 semillas** y una partición de validación; posible **sobreajuste**.

## Trabajo futuro

- Más semillas y datasets; **múltiples particiones** de validación.
- **Fine-tuning end-to-end** y otras representaciones.
- Presupuestos **mayores o adaptativos**, evaluación multi-fidelidad y transferencia entre arquitecturas.

## Fin de la presentación

Muchas gracias por su atención.

¿Preguntas?